

**Prognoza multivariată comparativă a unor indicatori  
macroeconomici prin intermediul modelului VAR și a rețelelor  
neuronale**

**1. Metodologie**

**Date Folosite:**

Indicatorii macroeconomici pe care i-am ales în vederea realizării acestui studiu de caz sunt:

- 1. Rata Șomajului în România - preluată de pe site-ul INSSE
- 2. HIPC al României - preluat de pe site-ul băncii europene
- 3. Rata de schimb RON-USD - preluat de pe site-ul băncii naționale

Perioadă studiată este Ianuarie 2009 - Mai 2024.

Date
Inflație
HIPC
Rata de schimb

Tabelul 5.1: Variabile folosite în analiză - prelucrare personală




Figura 5.1: Seria de timp a variabilelor studiate - prelucrare personală în python

## Elaborarea Modelului VAR

1) Analiza staționarității și a sezonality serilor de timp studiate

a) Seria Somajului:



Figura 5.2: Seria de timp a șomajului - prelucrare personală în python




Figura 5.3: ACF și PACF pentru seria șomajului - prelucrare personală în python

ADF	0.84
Ljung Box Test	0.0
Box-Pierce Test	0.0
Phillips-Perron	0.873
KPPS	0.0317

Tabelul 5.2: Rezultate teste serie șomaj - prelucrare personală

Se poate observă că rezultatele testelor ADF, PP și KPPS indică că seria este în mod cert nestaționară, de asemenea rezultatele testelor Ljung Box și Box-Pierce indică prezența semnificativă a autocorelației, lucru este evident și în graficul ACF din figura 5.3, fiind prezent un trend foarte pronunțat.

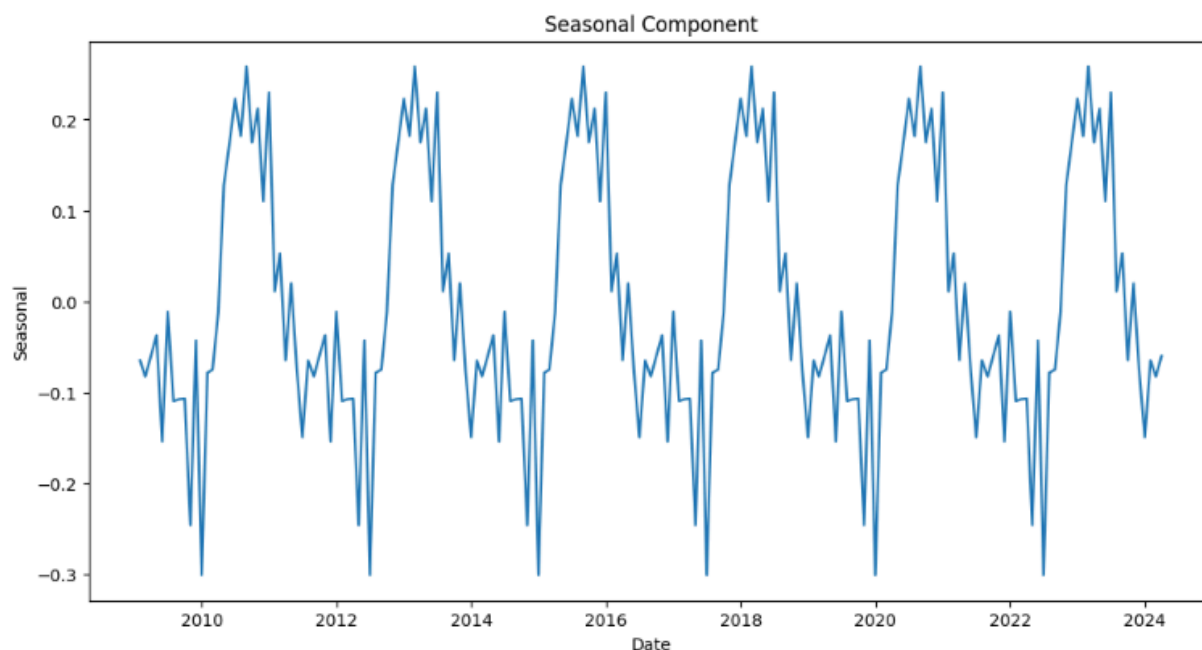


Figura 5.4: Componenta sezonieră a șomajului - prelucrare personală în python

Am continuat prin a extrage componenta sezonieră a seriei de timp, pentru a analiza prezența sezonality, care de altfel, este destul de pronunțată, în continuare urmând să aplic o diferențiere sezonieră de ordin 12.

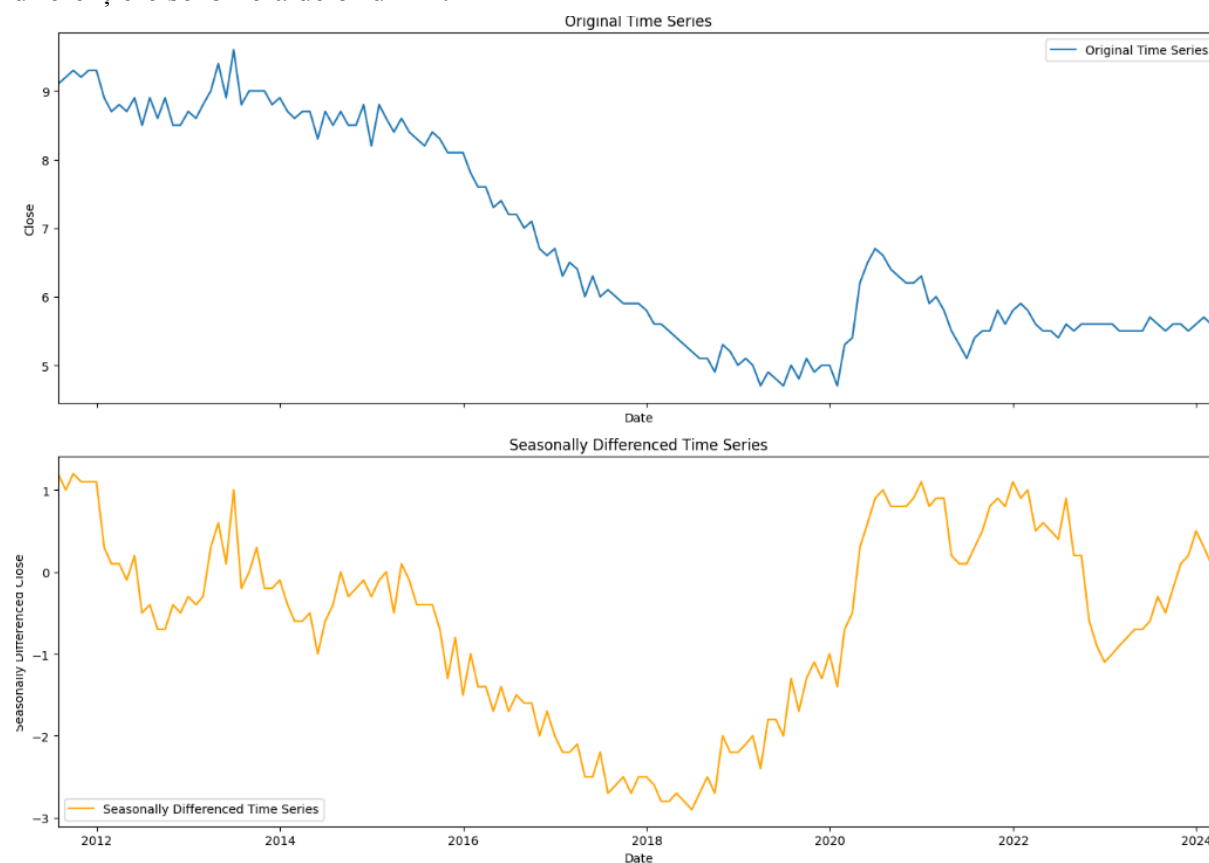


Figura 5.5: Comparație între seria somaj înainte și după diferențierea sezonieră - prelucrare personală în python

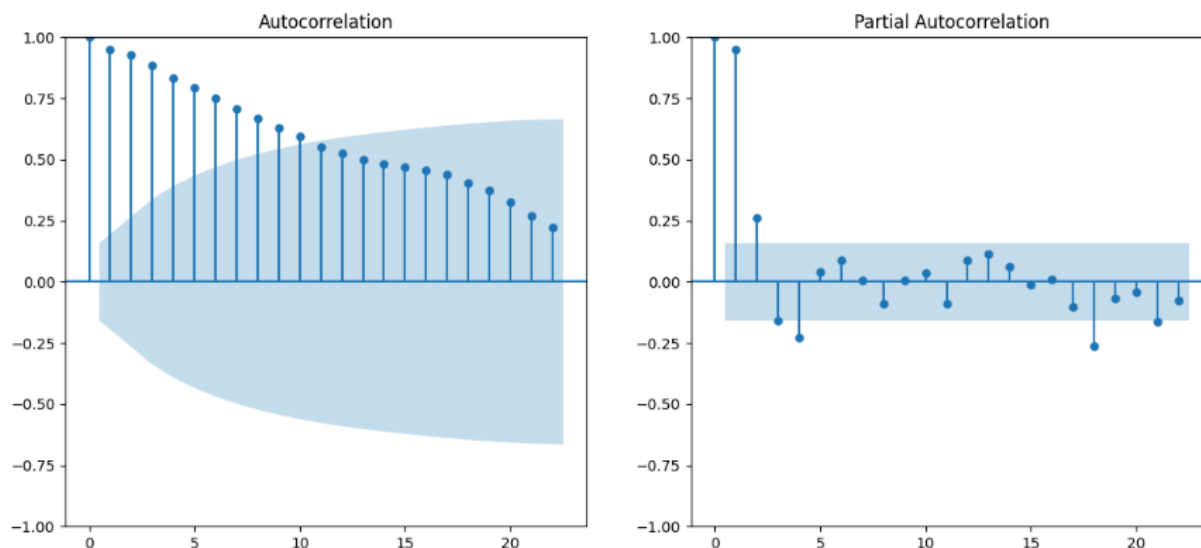


Figura 5.6: ACF și PACF somaj după diferențierea sezonieră - prelucrare personală în python

ADF	0.3146
Ljung Box Test	~0.0
Box-Pierce Test	~0.0
Phillips-Perron	0.215
KPPS	0.01

Tabelul 5.3: Rezultate teste serie șomaj diferențiată sezonier

Din tabelul, cât și din graficul de mai sus se poate observa că seria își păstrează caracterul nestaționar, testele având aceeași concluzie ca și înainte, iar pe ACF încă se vede clar prezența trendului.

Așadar, seria trebuie diferențiată.

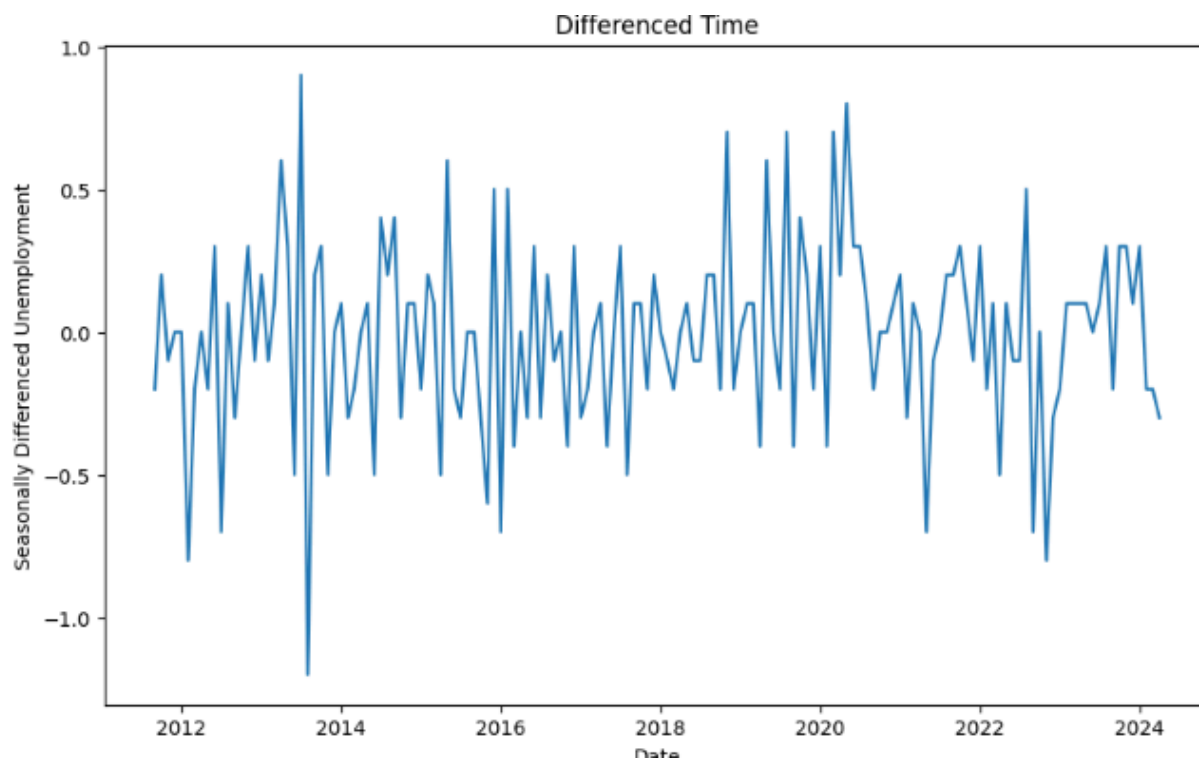


Figura 5.7: Seria Somaj în urma diferențierii - prelucrare personală în python




Figura 5.8: ACF și PACF somaj diferențiat - prelucrare personală în python

ADF	0.0035
Ljung Box Test	0.000568

Box-Pierce Test	~0.0
Phillips-Perron	0.0
KPPS	0.1

Tabelul 5.4: Rezultate teste serie șomaj diferențiată

De data aceasta, atât tabelul, cât și graficul de mai sus indică că seria este staționară, trendul fiind în mod vizibil eliminat, iar testele ADF și PP au o valoare a testului p mai mică de 0,05, iar KPPS nu respinge ipoteza nulă cum că seria ar fi staționară, în schimbă încă se remarcă prezența autocorelației între laguri.

### Concluzie:

Seria Somaj este Integrată de ordinul 1.

### b) Seria Inflației:




Figura 5.9 Seria de timp HIPC - prelucrare personală în python




Figura 5.10: ACF și PACF serie inflație - prelucrare personală în python

ADF	0.8317
Ljung Box Test	~0.0
Box-Pierce Test	~0.0
Phillips-Perron	0.344
KPPS	0.01

Tabelul 5.5: Rezultate teste serie inflație

Se poate observă că rezultatele testelor ADF, PP și KPPS indică că seria este în mod cert nestaționară, de asemenea rezultatele testelor Ljung Box și Box-Pierce indică prezența



semnificativă a autocorelației, lucru care este evident și în graficul ACF din figura 5.10, fiind prezent un trend foarte pronunțat.

Am continuat prin analizarea componentei sezoniere a seriei HIPC.




Figura 5.11: Componenta sezonieră a seriei de timp a inflației - prelucrare personală în python

Se remarcă prezența clară a unui trend sezonier, așa că se poate implementa diferențierea sezonieră de ordin 12.



Figura 5.12: Comparație între seria de timp originală și cea diferențiată sezonier - prelucrare personală în python




Figura 5.13: ACF și PACF inflație ajustată sezonier - prelucrare personală în python

ADF	0.5261
Ljung Box Test	~0.0
Box-Pierce Test	~0.0
Phillips-Perron	0.338
KPPS	0.01

Tabelul 5.6: Rezultate teste serie inflație ajustată sezonier

Se poate observa ca diferențierea sezonieră nu a produs aproape deloc schimbări asupra rezultatelor testelor, dar nici a graficelor ACF și PACF, este clar că seria trebuie diferențiată.




Figura 5.14: Seria inflație în urma diferențierii - prelucrare personală în python




Figura 5.15: ACF și PACF serie inflație diferențiată - prelucrare personală în python

ADF	0.0030
Ljung Box Test	0.000031
Box-Pierce Test	~0.0
Phillips-Perron	0.0
KPPS	0.1

Tabelul 5.7: Rezultate teste serie inflație ajustată sezonier

Atât tabelul, cât și graficul de mai sus indică că seria este staționară, trendul fiind în mod vizibil eliminat, iar testele ADF și PP au o valoare a testului p mai mică de 0,05, iar KPPS nu respinge ipoteza nulă cum că seria ar fi staționară, în schimbă încă se remarcă prezența autocorelației între laguri.


### Concluzie:

Seria Inflație este Integrată de ordinul 1.

b) Seria cursului de schimb valutar RON-USD:



Figura 5.16: Seria de timp a cursului de schimb - prelucrare personală în python



Figuta 5.17: ACF și PACF curs de schimb - prelucrare personală în python

ADF	0.7267
Ljung Box Test	~0.0
Box-Pierce Test	0.0
Phillips-Perron	0.765
KPPS	0.1

Tabelul 5.8: Rezultate teste serie schimb valutar

Se poate observă că rezultatele testelor ADF, PP ar indica că seria este nestaționară, însă ipoteza nulă a testului KPSS nu poate fi respinsă.

De asemenea rezultatele testelor Ljung Box și Box-Pierce indică prezența semnificativă a autocorelației, lucru este evident și in graficul ACF din figura 5.17, fiind prezent un trend foarte pronunțat.

Este necesară o analiză mai detaliată, mai precis extragerea componentului sezonier și eventual diferențierea sezonieră.

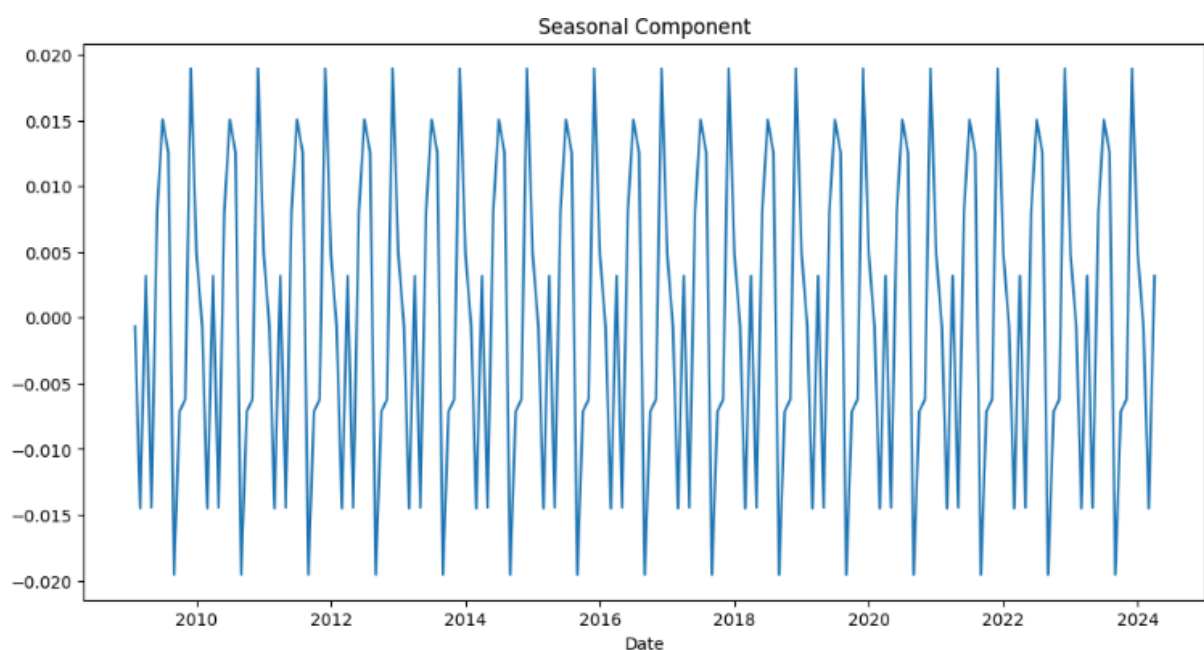


Figura 5.18: Componenta sezonieră a seriei cursului de schimb - prelucrare personală în python

În figura 5.18, se poate remarca prezența unui ciclu sezonier foarte pronunțat, așadar se va continua cu diferențierea sezoniera de ordin 12




Figura 5.19: Comparație între seria cursului de schimb înainte și după diferențierea sezonieră - prelucrare personală în python

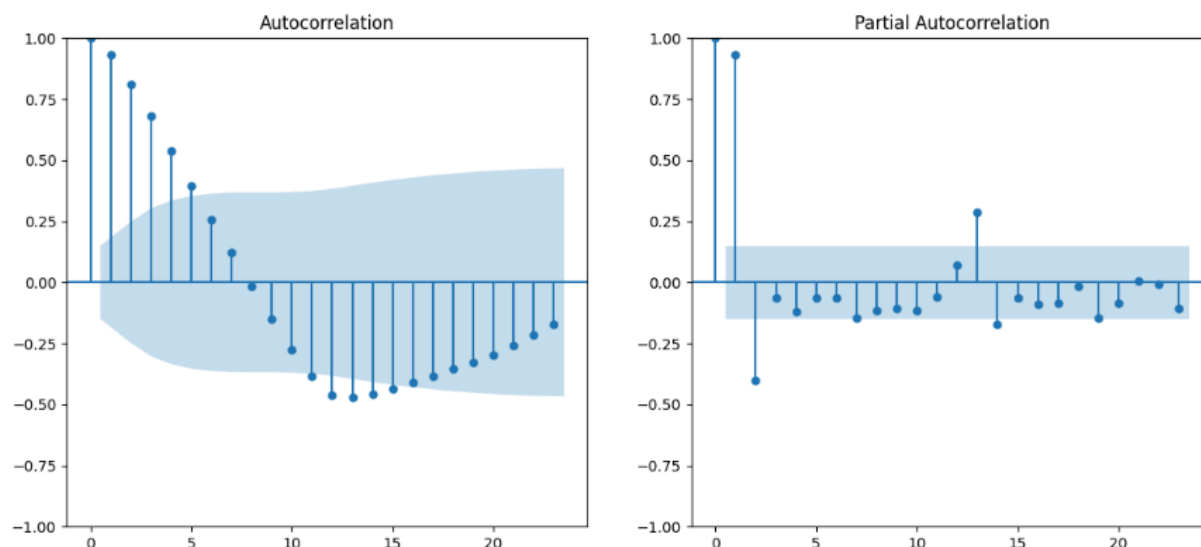


Figura 5.20: ACF și PACF în urma diferențiere sezoniere a cursului de schimb - prelucrare personală în python

ADF	0.0160
Ljung Box Test	~0.0
Box-Pierce Test	~0.0
Phillips-Perron	0.020
KPPS	0.1

Tabelul 5.9: Rezultate teste serie schimb valutar în urma diferențierii sezoniere

Aruncând o privire la tabelul de mai sus, se poate observa că serie este staționară potrivit testelor ADF și PP, cât și KPPS, însă Ljung Box, Box Pierce și graficele dom figura 5.20, indică prezența unei autocorelații foarte puternice care are loc succesiv pentru primele 4 laguri din ACF și primele 2 din PACF, în acest context, am considerat că diferențierea ar fi adecvată.






Figura 5.21: Seria cursului de schimb în urma diferențierii - prelucrare personală în python




Figura 5.22: ACF și PACF rata de schimb diferențiată - prelucrare personală în python

ADF	~0.0
-----	------

Ljung Box Test	~0.0
Box-Pierce Test	~0.0
Phillips-Perron	~0.0
KPPS	0.1

Tabel 5.10: Rezultatele testelor seriei de curs de schimb în urma diferențierii

Cu toate că, autocorelația încă pare să fie prezentă, aceasta nu este atât de pronunțată ca înainte, de asemenea. seria este mai mult ca sigur staționară în acest moment, respingând ipotezele nule ale ADF și PP cu certitudine, și nereușind să o respingă pe cea a testului KPSS

### **Concluzie:**

Seria Cursului de schimb este Integrată de ordinul 1.

Prin urmare se poate trece la pasul următor în elaborarea modelului VAR.

### **Testarea Cointegrității Johansen:**

Având în vedere că am demonstrat anterior că toate seriile de timp incluse în analize sunt integrate de ordin 1, se poate proceda la următorul pas, care implică verificarea existenței cointegrității între seriile de timp.

Numărul optim de laguri care trebuie selectat este 2, lucru redat de rezultatele următoarelor criterii:

AIC	2
BIC	2
FPE	2
HQIC	2

Tabel 5.11: Criterii pentru selecția lagurilor optime

Test Statistic	Value	Critical Value (90%)	Critical Value (95%)	Critical Value (99%)	Conclusion Based on Critical Value (95%)
Trace Statistic					
Component 1	20.18	27.07	29.80	35.46	No cointegration (20.1786 < 29.7961)
Component 2	7.67	13.43	15.49	19.93	No cointegration (7.6675 < 15.4943)
Component 3	1.02	2.71	3.84	6.63	No cointegration (1.0173 < 3.8415)
Maximum Eigenvalue Statistic					
Component 1	12.51	18.89	21.13	25.87	No cointegration (12.5111 < 21.1314)
Component 2	6.65	12.30	14.26	18.52	No cointegration (6.6502 < 14.2639)
Component 3	1.02	2.71	3.84	6.63	No cointegration (1.0173 < 3.8415)

Tabelul 5.12: Rezultatele testului Johansen

Analizând tabelul 5.12, se poate deduce că nu există relații de cointegrare între cele 3 variabile alese pentru studiu, prin urmare se poate continua cu rularea modelului VAR în prima diferență.

Potențiale implicații economice pentru lipsa cointegralității:

1. Absența cointegrării indică faptul că nu există o relație stabilă pe termen lung între șomaj, inflație și rata de schimb. Aceasta înseamnă că variațiile pe termen lung ale uneia dintre aceste variabile nu pot fi explicate în mod direct prin variațiile pe termen lung ale celorlalte două.
2. Politicile economice care vizează șomajul, inflația și rata de schimb pot fi considerate mai independente. Spre exemplu, măsurile pentru reducerea șomajului ar putea avea efecte limitate asupra inflației și ratei de schimb pe termen lung, și viceversa.

3. În absența cointegrării, modelele VAR implementate pe prima diferență a seriei multivariate sunt adecvate pentru a analiza relațiile dinamice pe termen scurt între variabile, așadar este posibil ca cei 3 indicatori economici să se influențeze una pe alta mai degrabă pe termen scurt decât pe termen lung.

Estimarea modelului VAR pe seria de timp timp diferențiată

Attribute	Value
Model	VAR (Vector Autoregression)
Method	OLS (Ordinary Least Squares)
Number of Equations	3.00
Number of Observations (Nobs)	143.00
Log Likelihood	40.08
AIC (Akaike Information Criterion)	-8.78
BIC (Bayesian Information Criterion)	-8.35
HQIC (Hannan-Quinn Information Criterion)	-8.60
FPE (Final Prediction Error)	0.00
Det(Omega_mle)	0.00

Tabelul 5.13: Statistici descriptive ale modelului VAR

Atributul Log Likelihood are o valoare pozitivă, iar AIC, BIC și HQIC au o valoare negativă, indicând că modelul este suficient de robust pentru a descrie variabilele, totodată cu cât valoarea FPE este mai mică, cu atât acuratețea prezicerii este mai mare.

Din punct de vedere economic, faptul că modelul VAR rezultat din seria de timp multivariată diferențiată este unul destul de robust, se poate concluziona că într-o anumită măsură cei trei indicatori economici se pot influența reciproc.

Variable	Coefficient	Std. Error	t-stat	p-value
const	-0.02	0.02	-1.15	0.25
L1.somaj	-0.39	0.08	-4.58	0.00
L1.inflatie	-0.04	0.03	-1.09	0.28
L1.rata_schimb	-0.02	0.24	-0.07	0.94
L2.somaj	0.10	0.09	1.19	0.24
L2.inflatie	-0.04	0.03	-1.20	0.23
L2.rata_schimb	0.05	0.24	0.20	0.84

Tabelul 5.14: Ecuația șomajului exprimată de VAR

Singurul coeficient semnificativ statistic în toată această ecuație este primul lag al șomajului. Care are un efectiv negativ asupra valorii prezente.

Un coeficient negativ sugerează că o creștere în șomaj la perioada anterioară (t-1) duce la o scădere a șomajului în perioada curentă (t). Acest lucru poate indica un efect de autoreglare sau de corecție în timp.

Variable	Coefficient	Std. Error	t-stat	p-value
const	-0.02	0.05	-0.45	0.66
L1.somaj	0.14	0.23	0.62	0.54
L1.inflatie	0.19	0.09	2.23	0.03
L1.rata_schimb	0.36	0.65	0.55	0.58
L2.somaj	0.12	0.23	0.53	0.59
L2.inflatie	0.10	0.09	1.18	0.24
L2.rata_schimb	1.11	0.65	1.72	0.09

Tabelul 5.15: Ecuația inflației explicată de VAR

Pentru un coeficient de încredere de peste 95%, inflație este influențată pozitiv de primul său lag, iar pentru un coeficient de încredere de 90%, rata de schimb din cel de-al doilea lag o

influențează pozitiv. Așadar modelul sugerează că o creștere a inflației în perioada anterioară ( $t-1$ ) duce la o creștere a inflației în perioada curentă ( $t$ ). Acest lucru indică persistența inflației, unde inflația din trecut continuă să influențeze inflația prezentă.

De asemenea, modelul sugerează că o creștere în rata de schimb cu două perioade în urmă poate avea un impact de creștere asupra inflației în perioada curentă, deși semnificația statistică este oarecum limitată.

Variable	Coefficient	Std. Error	t-stat	p-value
const	0.00	0.01	0.34	0.73
L1.somaj	-0.04	0.03	-1.49	0.14
L1.inflatie	0.00	0.01	0.04	0.97
L1.rata_schimb	0.20	0.09	2.28	0.02
L2.somaj	-0.03	0.03	-0.94	0.35
L2.inflatie	-0.01	0.01	-1.02	0.31
L2.rata_schimb	0.05	0.09	0.64	0.52

Tabelul 5.16: Ecuația ratei de schimb explicată de VAR

Singurul coeficient semnificativ statistic descris în tabelul de mai sus îl reprezintă rata de schimb din lagul 1, care are o influență pozitivă, prin urmare o creștere a ratei de schimb în perioada anterioară duce la o creștere a inflației în perioada curentă.

Variables	somaj	inflatie	rata_schimb
somaj	1.00	-0.08	0.03
inflatie	-0.08	1.00	-0.16
rata_schimb	0.03	-0.16	1.00

Tabelul 5.17: Matricea corelației rezidurilor

În tabel se observă că corelația dintre rezidurile variabilelor este destul de nesemnificativă, cea mai puternică corelație fiind între rata de schimb și inflație, iar cea mai slabă între rata de schimb și somaj. Valorile foarte mici ale coeficienților de corelație sugerează că șocurile neanticipate în șomaj, inflație și rata de schimb sunt în mare parte independente unele de altele. Acest lucru poate indica faptul că fiecare dintre aceste variabile este influențată de factori diferiți și nu reacționează simultan la aceiași șocuri economice.

### Cauzalitatea Granger:

Următoarea etapă constă în verificarea relațiilor de cauzalitate dintre variabile, în acest scop în urma rulării codului, am realizat următoarele tabele:

Number of Lags	Test Type	Test Statistic	p-value	df	Conclusion ( $p < 0.05$ )
1.00	SSR Based F Test	F=3.3405	0.07	1, 179	No Causality
	SSR Based Chi2 Test	Chi2=3.3965	0.07	1.00	No Causality
	Likelihood Ratio Test	Chi2=3.3652	0.07	1.00	No Causality
	Parameter F Test	F=3.3405	0.07	1, 179	No Causality
2.00	SSR Based F Test	F=1.1935	0.31	2, 176	No Causality
	SSR Based Chi2 Test	Chi2=2.4547	0.29	2.00	No Causality
	Likelihood Ratio Test	Chi2=2.4382	0.30	2.00	No Causality
	Parameter F Test	F=1.1935	0.31	2, 176	No Causality

Tabelul 5.18: Cauzalitate Granger Somaj - Inflație

După cum se poate observa și în tabelul de mai sus, nu există cauzalitate din partea șomajului în inflație.

Faptul că nu există o relație de cauzalitate directă evidențiată între șomaj și inflație sugerează că relațiile economice dintre aceste variabile ar putea fi mai complexe și influențate de alți factori care nu sunt capturați în modelul simplu de cauzalitate.

Number of Lags	Test Type	Test Statistic	p-value	df	Conclusion ( $p < 0.05$ )
1.00	SSR Based F Test	F=1.4824	0.23	1, 179	No Causality
	SSR Based Chi2 Test	Chi2=1.5073	0.22	1.00	No Causality
	Likelihood Ratio Test	Chi2=1.5011	0.22	1.00	No Causality
	Parameter F Test	F=1.4824	0.23	1, 179	No Causality
2.00	SSR Based F Test	F=3.0119	0.05	2, 176	Possible Causality
	SSR Based Chi2 Test	Chi2=6.1950	0.05	2.00	Possible Causality
	Likelihood Ratio Test	Chi2=6.0914	0.05	2.00	Possible Causality
	Parameter F Test	F=3.0119	0.05	2, 176	Possible Causality

Tabelul 5.19: Cauzalitate Granger Inflație - Șomaj

Pe baza rezultatelor testelor din tabelul 5.19, se pare că este posibil să existe cauzalitate din partea inflației în șomaj, în lagul al doilea.

Rezultatele sugerează că inflația poate avea un efect causal asupra șomajului, dar acest efect devine evident doar după două perioade. Acest lucru ar putea indica faptul că ajustările economice la schimbările în inflație necesită timp pentru a se reflecta în nivelurile șomajului.

Prin urmare, dacă inflația cauzează ipotetic șomajul cu un decalaj de două perioade, autoritățile de politici economice trebuie să ia în considerare acest efect întârziat atunci când formulează măsuri pentru controlul inflației și reducerea șomajului. De exemplu, măsurile anti-inflaționiste ar putea avea nevoie de timp pentru a produce efecte asupra pieței muncii.

Number of Lags	Test Type	Test Statistic	p-value	df	Conclusion ( $p < 0.05$ )
1.00	SSR Based F Test	F=1.8161	0.18	1, 179	No Causality
	SSR Based Chi2 Test	Chi2=1.8466	0.17	1.00	No Causality
	Likelihood Ratio Test	Chi2=1.8373	0.18	1.00	No Causality
	Parameter F Test	F=1.8161	0.18	1, 179	No Causality
2.00	SSR Based F Test	F=2.4436	0.09	2, 176	No Causality
	SSR Based Chi2 Test	Chi2=5.0261	0.08	2.00	No Causality
	Likelihood Ratio Test	Chi2=4.9575	0.08	2.00	No Causality
	Parameter F Test	F=2.4436	0.09	2, 176	No Causality

Tabelul 5.20: Cauzalitate Granger Șomaj - Rată de schimb

După cum se poate observa și în tabelul 5.20, nu există cauzalitate din partea șomajului în rata de schimb, atât pentru primul lag, cât și pentru cel de-al doilea.

Testele de cauzalitate nu indică o relație causală semnificativă între șomaj și rata de schimb, nici la un lag, nici la două laguri, lucru care sugerează că variațiile șomajului nu cauzează variații în rata de schimb și viceversa, în cadrul perioadei și modelului analizat.



Number of Lags	Test Type	Test Statistic	p-value	df	Conclusion ( $p < 0.05$ )
1.00	SSR Based F Test	F=5.5600	0.02	1, 179	Granger Causality
	SSR Based Chi2 Test	Chi2=5.6532	0.02	1.00	Granger Causality
	Likelihood Ratio Test	Chi2=5.5672	0.02	1.00	Granger Causality
	Parameter F Test	F=5.5600	0.02	1, 179	Granger Causality
2.00	SSR Based F Test	F=1.9760	0.14	2, 176	No Causality
	SSR Based Chi2 Test	Chi2=4.0643	0.13	2.00	No Causality
	Likelihood Ratio Test	Chi2=4.0193	0.13	2.00	No Causality
	Parameter F Test	F=1.9760	0.14	2, 176	No Causality

Tabelul 5.21: Cauzalitate Granger Rată de schimb - Șomaj

Tabelul de mai sus descrie o relație de cauzalitate din partea ratei de schimb în șomaj în cadrul primului lag.

Testele indică o relație de cauzalitate Granger între rata de schimb și șomaj la un lag. Aceasta sugerează că variațiile în rata de schimb influențează șomajul pe termen scurt. De exemplu, o depreciere a monedei naționale poate duce la o creștere a șomajului într-o perioadă ulterioară, posibil datorită scăderii puterii de cumpărare și a importurilor mai scumpe care afectează costurile de producție.

De asemenea, se poate concluziona, având în vedere scenariul că variațiile pe termen scurt în rata de schimb afectează șomajul, că politicile economice care vizează stabilizarea ratei de schimb pot avea efecte benefice asupra șomajului pe termen scurt

Number of Lags	Test Type	Test Statistic	p-value	df	Conclusion (p < 0.05)
1.00	SSR Based F Test	F=0.2115	0.65	1, 179	No Causality
	SSR Based Chi2 Test	Chi2=0.2150	0.64	1.00	No Causality
	Likelihood Ratio Test	Chi2=0.2149	0.64	1.00	No Causality
	Parameter F Test	F=0.2115	0.65	1, 179	No Causality
2.00	SSR Based F Test	F=0.6542	0.52	2, 176	No Causality
	SSR Based Chi2 Test	Chi2=1.3455	0.51	2.00	No Causality
	Likelihood Ratio Test	Chi2=1.3405	0.51	2.00	No Causality
	Parameter F Test	F=0.6542	0.52	2, 176	No Causality

Tabelul 5.22: Cauzalitate Granger Inflație - Rată de schimb

Pe baza tabelului de mai sus, se poate concluziona că nu există cauzalitate din partea inflației asupra ratei de schimb, fapt care sugerează că variațiile inflației nu cauzează variații în rata de schimb și invers, în cadrul perioadei și modelului analizat.

Number of Lags	Test Type	Test Statistic	p-value	df	Conclusion (p < 0.05)
1.00	SSR Based F Test	F = 2.8713	0.09	1, 179	No Causality
	SSR Based Chi2 Test	Chi2 = 2.9194	0.09	1.00	No Causality
	Likelihood Ratio Test	Chi2 = 2.8962	0.09	1.00	No Causality
	Parameter F Test	F = 2.8713	0.09	1, 179	No Causality
2.00	SSR Based F Test	F = 1.6436	0.20	2, 176	No Causality
	SSR Based Chi2 Test	Chi2 = 3.3806	0.18	2.00	No Causality
	Likelihood Ratio Test	Chi2 = 3.3494	0.19	2.00	No Causality
	Parameter F Test	F = 1.6436	0.20	2, 176	No Causality

Tabelul 5.23: Cauzalitate Granger Rată de schimb - Inflație

Pe baza tabelului de mai sus, se poate concluziona că nu există cauzalitate din partea ratei de schimb asupra inflației pentru un interval de încredere mai mare de 95%, însă în cadrul primului lag poate fii explicată relația de cauzalitate pentru un interval de încredere de 90%, ceea ce poate indica totuși un anumit nivel de cauzalitate.

Prin urmare rezultatele testelor indică o relație de cauzalitate marginal semnificativă între rata de schimb și inflație la un lag, sugerând că variațiile pe termen scurt în rata de schimb pot influența inflația. Totuși, această relație nu este suficient de puternică pentru a fi considerată semnificativă la nivelul de 0.05. Pe termen mediu, nu există o relație cauzală semnificativă între rata de schimb și inflație. Aceste concluzii subliniază importanța monitorizării efectelor pe termen scurt ale variațiilor ratei de schimb asupra inflației, dar și recunoașterea limitărilor în semnificația statistică a acestor relații.

## Descompunerea varianței




Figura 5.23: reprezentare grafică a decompunerii varianței - prelucrare personală în python

Graficul de mai sus arată procentul din varianța fiecărei variabile explicat de toate variabilele incluse în modelul VAR. Se poate observa că șomajul este aproape în totalitate explicat doar de el însuși, inflația se află într-o situație similară, dar odată cu trecerea lagurilor tot mai mult din ea este explicată de rata de schimb, ajungând să fie explicată de aceasta în jur de 5%. Pe de altă parte, rata de schimb este explicată încă de la început într-o proporție apropiată de 5%, de celelalte variabile, mai precis 1,2-1,7% de șomaj și 2,6 - 3,3% de inflație.

Concluzii economice:

1. Politicile care vizează direct șomajul, cum ar fi stimulentele pentru angajare sau reformele pieței muncii, ar trebui să fie prioritate, deoarece inflația și rata de schimb nu au un impact semnificativ asupra șomajului.
2. Politicile monetare ar trebui să ia în considerare impactul ratei de schimb asupra inflației. Stabilitatea ratei de schimb poate ajuta la controlul inflației pe termen mediu.
3. Pentru stabilizarea ratei de schimb, este important să se monitorizeze și să se gestioneze atât inflația, cât și condițiile pieței muncii.

## Concluzie

Comparând rezultatele analizei VAR cu ipotezele clasice, se observă că, deși există anumite conformități, cum ar fi influența ratei de schimb asupra inflației, multe dintre relațiile propuse de ipotezele clasice, cum ar fi relația inversă puternică între șomaj și inflație, nu se manifestă clar în datele actuale.

## Elaborarea modelelor de deep learning multivariate:

### 1) Prelucrarea Datelor

Pentru început, am calculat modificările din perioada curentă față de perioada anterioară pentru toate cele 3 variabile incluse în analiză și le-am inclus într-un nou set de date.

Data	Șomaj (%)	Inflație (%)	Rata de Schimb	Șomaj Anterior (%)	Inflație Anterioară (%)	Rata de Schimb Anterioară	Modificare Șomaj	Modificare Inflație	Modificare Rata de Schimb
31/01/2009	7.92	6.84	3.22	0.00	0.00	0.00	0.00	0.00	0.00
28/02/2009	8.20	6.92	3.35	7.92	6.84	3.22	0.2747	0.08	0.12
31/03/2009	8.12	6.74	3.31	8.20	6.92	3.35	-0.0756	-0.18	-0.04
30/04/2009	8.10	6.42	3.18	8.12	6.74	3.31	-0.0259	-0.32	-0.13
31/05/2009	8.23	5.91	3.08	8.10	6.42	3.18	0.131	-0.51	-0.09

Tabelul 5.24: Set de date care include modificarea procentuală a indicatorilor

Acest set de date, trebuie împărțit în 3 subseturi, în funcție de variabila previzionată, fiecare subset trebuie să aibă pe prima coloană variabila dependentă, urmată apoi de variabilele independente, dintre care una este modificarea procentuală a variabilei dependente.

Data	Șomaj (%)	Inflație (%)	Rata de Schimb	Modificarea Șomaj
31/01/2009	7.92	6.84	3.22	0
28/02/2009	8.20	6.92	3.35	0.2747
31/03/2009	8.12	6.74	3.31	-0.0756
30/04/2009	8.10	6.42	3.18	-0.0259
31/05/2009	8.23	5.91	3.08	0.131

Tabelul 5.25: Setul de date folosit pentru antrenarea modelului care prezice șomajul

Data	Inflație (%)	Șomaj (%)	Rata de Schimb	Modificare Inflație
31/01/2009	6.84	7.92	3.22	0.00
28/02/2009	6.92	8.20	3.35	0.08
31/03/2009	6.74	8.12	3.31	-0.18
30/04/2009	6.42	8.10	3.18	-0.32
31/05/2009	5.91	8.23	3.08	-0.51

Tabelul 5.26: Setul de date folosit pentru antrenarea modelului care prezice inflația

Data	Rata de Schimb	Șomaj (%)	Inflație (%)	Modificare Rata de
31/01/2009	3.22	7.92	6.84	0.00
28/02/2009	3.35	8.20	6.92	0.12
31/03/2009	3.31	8.12	6.74	-0.04
30/04/2009	3.18	8.10	6.42	-0.13
31/05/2009	3.08	8.23	5.91	-0.09

Tabelul 5.27: Setul de date folosit pentru antrenarea modelului care prezice rata de schimb

Ca și în cadrul studiului de caz 1, am decis să procedez prin normalizarea datelor cu funcția minmax cu valori în intervalul  $[-1;1]$  și am împărțit datele în felul următor: primele 80% observații în setul de antrenament și ultimele 20% în setul de testare.

Data	somaj	inflatie	rata_schimb	modificare_somaj
31/01/2009	0.31	0.71	-0.52	0.03
28/02/2009	0.42	0.72	-0.37	0.38
31/03/2009	0.39	0.69	-0.42	-0.06
30/04/2009	0.38	0.64	-0.58	0.00
31/05/2009	0.43	0.55	-0.69	0.20

Tabelul 5.28: Setul pentru șomaj după normalizare

Odată normalizate, datele sunt convertite în secvențe de câte 8 observații și sunt împărțite în batch-uri de câte 10, lucru valabil pentru toate cele 3 subseturi de date.

## 2) Definirea rețelelor neuronale

rețeaua are 4 neuroni în stratul de intrare, fiecare corespunde uneia dintre cele 4 caracteristici ale setului de date ( șomajul, inflația, rata de schimb și modificare procentuală corespunzătoare variabilei dependente ), urmați apoi de doua straturi ascunse a câte 84 de neuroni fiecare, în cele din urmă rezultând într-o singură valoare de ieșire.

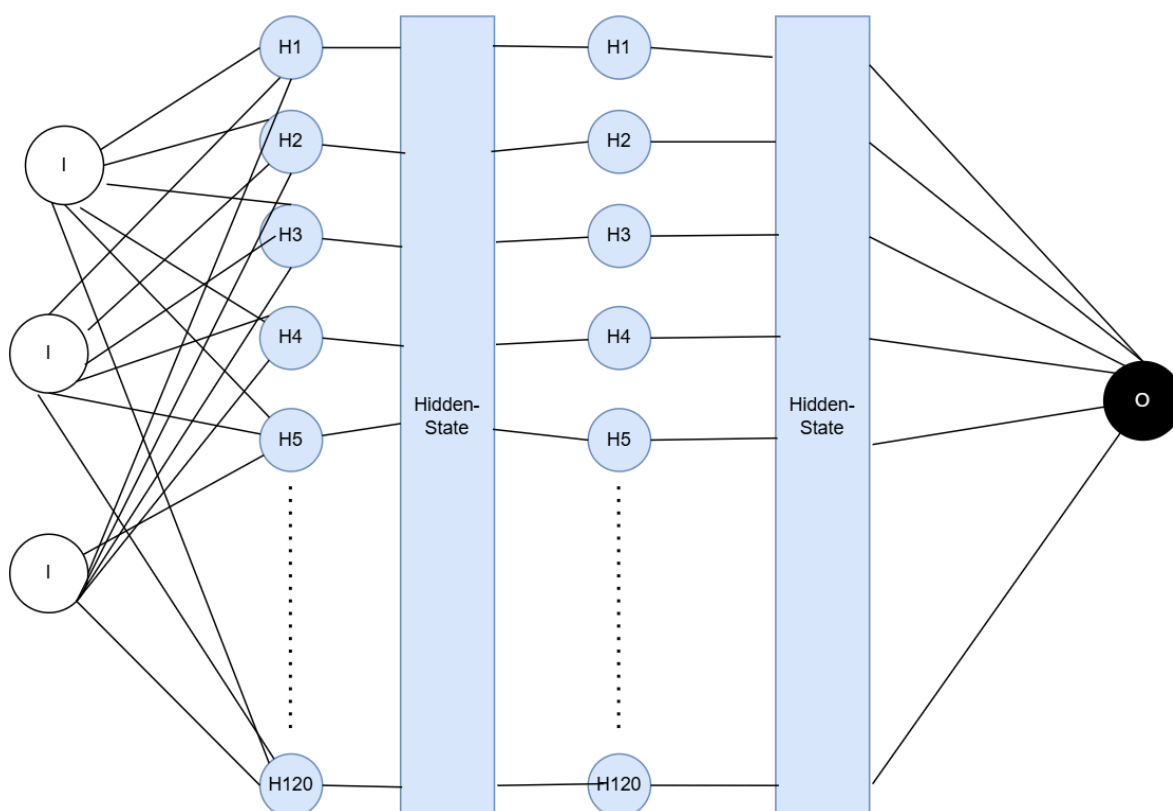


Figura 5.24 modelul rețelei neuronale pentru prognoza multivariată - prelucrare personală în draw.io

Caracteristicile meta parametrilor:

- Numărul de epoci de antrenament este 10
- Rata de învățare setată este 0.001
- Funcția de pierdere este redată de MSE
- Optimizatorul folosit este ADAM

### 3) Antrenarea modelului

#### a) Șomaj

Model	MAE	MSE	RMSE
LSTM	0.18	0.05	0.23
GRU	0.89	0.81	0.90
RNN	1.08	1.19	1.09

Tabelul 5.29: Erori generate de fiecare model în previziunea Șomajului

În tabel se poate observa diferența considerabilă între LSTM și celelalte modele, acesta are pe departe, cele mai mici valori ale erorilor în toate cele 3 categorii.

În schimb. Între GRU și RNN nu se remarcă o diferență atât de mare, cu toate ca GRU este superior în toate cele 3 categorii de erori.

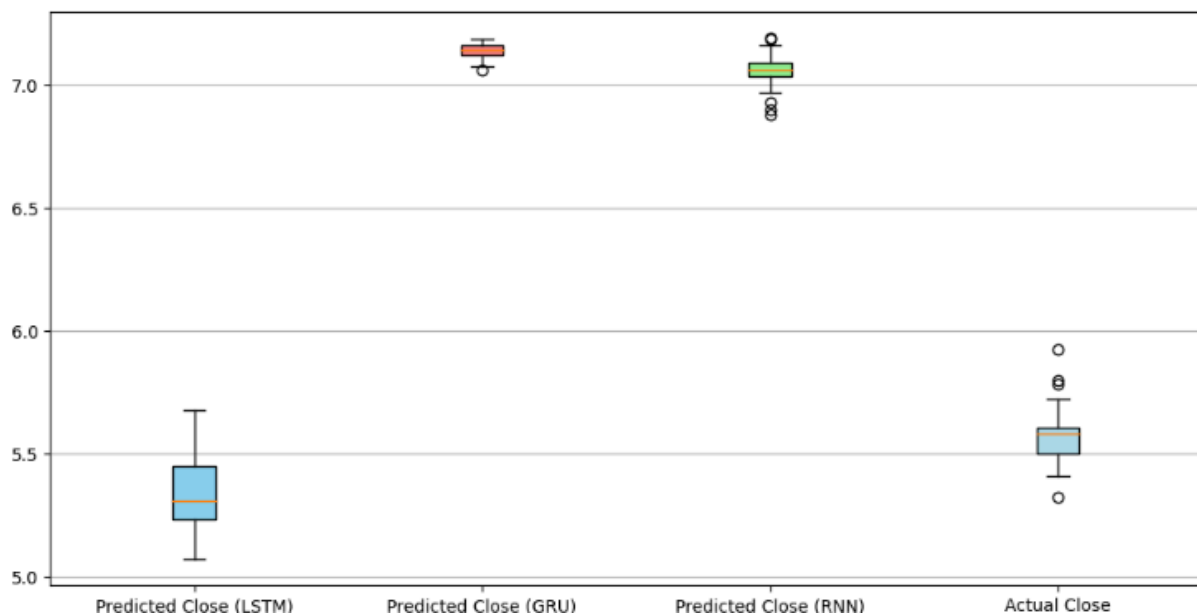


Figura 5.25: Boxploturi ale șomajului previzionat - prelucrare personală în python

În figură se poate observa o diferență foarte pronunțată între raza de valori pe care LSTM-ul a prezis-o față de cea a celorlalte rețele, această fiind mult mai aproape de valorile reale decât celelalte două modele.

Se remarcă și prezenta valorile de tip outlier în datele originale, ceea ce este interesant e că previziunile realizate de GRU și RNN prezintă și ele valori outlier, însă LSTM, care este cea mai apropiată de realitate, nu are niciun singur outlier în previziuni.

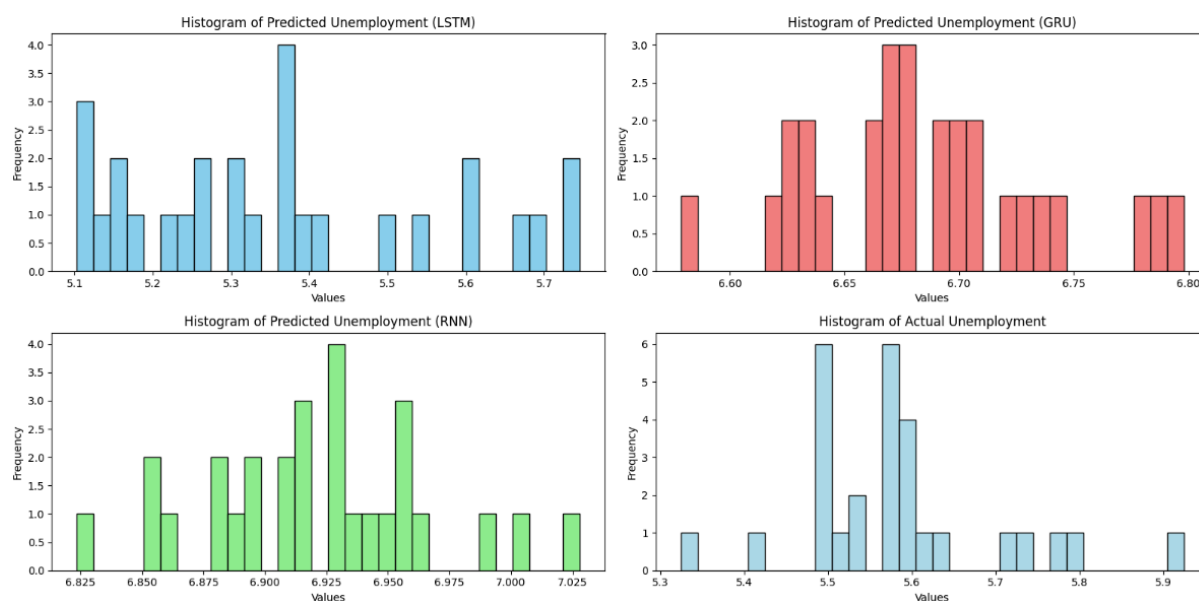


Figura 5.26: Histograme ale Șomajului previzionat - prelucrare personală în python

Din figura de mai sus reiese că niciunul dintre modele nu a reușit să capteze cu exactitate frecvențele valorilor, însă toate, în special GRU, au identificat corect că multe dintre valori au frecvența 0.

## b) Inflație

Model	MAE	MSE	RMSE
LSTM	5.52	35.22	5.93
GRU	8.30	75.92	8.71
RNN	8.44	78.81	8.88

Tabelul 5.30: Erori generate de fiecare model în previziunea Inflației



Ca și în cazul modelelor pentru șomaj LSTM are cele mai mici erori, însă de data aceasta diferența nu este atât de pronunțată între LSTM și celelalte două modele. De asemenea, erorile GRU și RNN sunt foarte aproape de a fii identice.

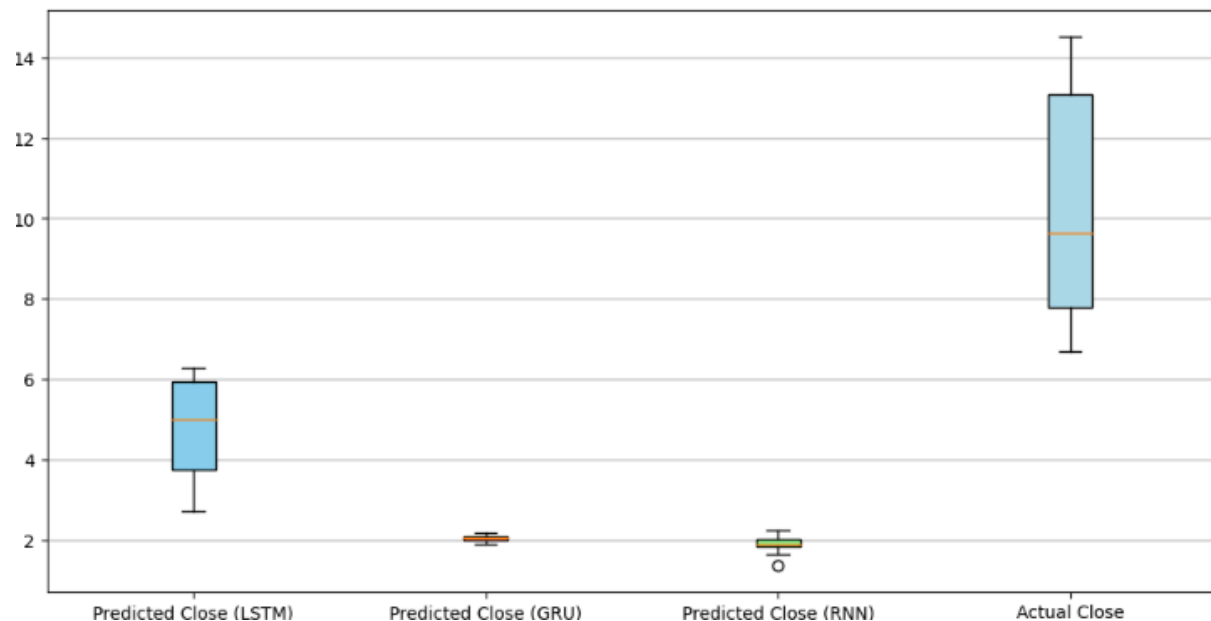


Figura 5.27: Boxploturi ale inflației previzioante - prelucrare personală în python

În continuare, între LSTM și celelalte două modele există diferență masivă a distribuțiilor, cele din urmă având o rază a valorile previzionate total detașată de realitate, de asemenea în timp ce în setul valorilor actuale nu există outliers, RNN a produsul unul.

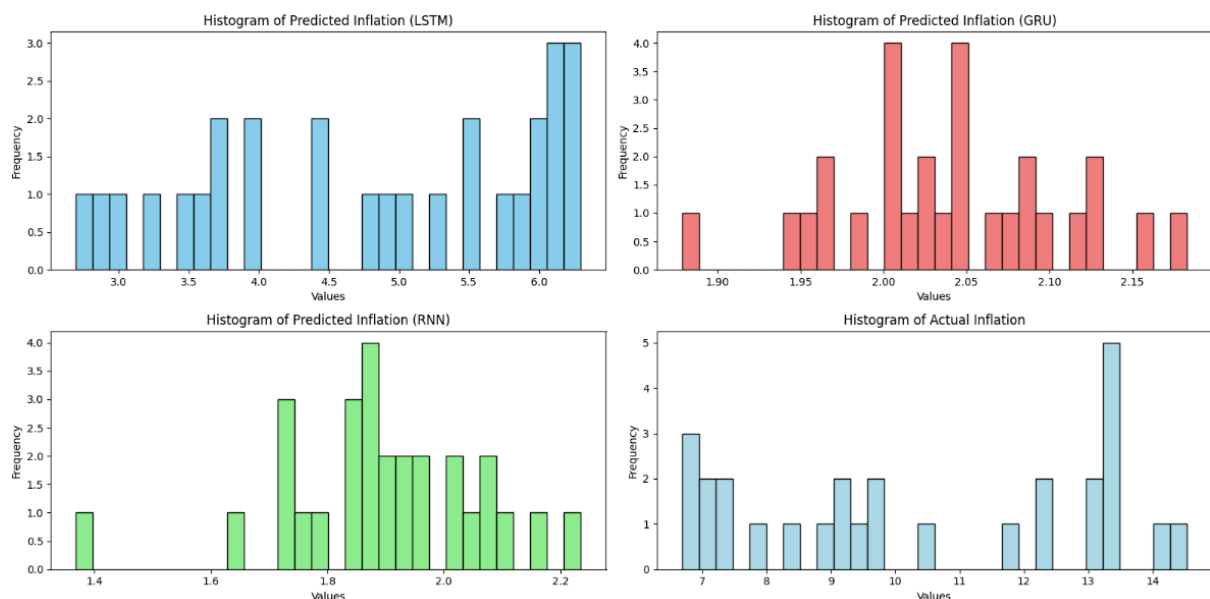


Figura 5.28: histograme ale inflației previzionate - prelucrare personală în python

Din figura de mai sus reiese că niciunul dintre modele nu a reușit să capteze cu exactitate frecvențele valorilor, LSTM a fost destul de aproape, cea mai mare greșală făcută de aceasta fiind alocarea unor frecvențe mai mari valorilor celor mai ridicate.

### c) Rata de schimb

Model	MAE	MSE	RMSE
LSTM	0.21	0.06	0.25
GRU	1.05	1.14	1.07
RNN	1.05	1.13	1.06

Tabelul 5.30: Erori generate de fiecare model în previziunea ratei de schimb

Diferența între LSTM și celelalte modele este încă o dată foarte aparentă, aceasta având pe departe cele mai mici erori în toate categoriile analizate.

De asemenea, GRU și RNN au practic erori identice.




Figura 5.29: Boxploturi ale ratei de schimb previzionate - prelucrare personală în python

Încă o dată, distribuția modelului LSTM este pe departe cea mai apropiată de realitate, iar cele ale RNN și GRU sunt aproape identice între ele.

Se remarcă și prezenta valorilor de tip outlier în datele originale, însă niciunul dintre modele nu a făcut previziuni care să genereze outlieri.




Figura 5.30: Histograme ale ratei de schimb previzionate - prelucrare personală în python

În figură se poate observa că frecvențele atribuite de modelul LSTM sunt semnificativ de apropiate de cele reale, principala diferență constând în faptul că LSTM a acordat o apropiere fiecărei valori cel puțin frecvență, în timp ce datele actuale au o frecvență de 0 pentru o bună parte din valori.

Se poate observa și că frecvențele atribuite de modelele GRU și RNN sunt detașate de cele reale.

## 2. Rezultate:




Figura 5.31: Prognoza comparativă a șomajului - prelucrare personală în python

După cum se poate observa în grafic, rețelele neuronale se descurcă mult mai bine în realizarea previziunii ratei șomajului, datele previzionate de VAR fiind complet detașate de realitate, în timp model LSTM surprinde foarte bine modificarea șomajului, cu toate GRU și RNN par să realizeze o prognoză statică, care mai mult ca sigur va deveni complet eronată dacă orizontul prognozei crește




Figura 5.32: Prognoza comparativă a inflației - prelucrare personală în python

Dintre toate modelele de previziune folosite, prognoza realizată de VAR are valorile cele mai apropiate de inflația reală, însă aceasta nu pare să reacționeze la potențiale schimbări bruște, în schimb prognoza realizată de LSTM, cu toate că are valorile îndepărtate de cele reale, pare mai puțin statică.

În schimb GRU și RNN nu reușesc să realizeze previziuni apropiate de realitate.




Figura 5.33: Prognoza comparativă a ratei de schimb - prelucrare personală în python

Prognoza realizată de LSTM este cea mai apropiată de realitate, în timp ce prognoza realizată de VAR urmează un trend strict crescător, ajungând în cele din urmă să prezică ceva complet diferit de realitate. Modelele GRU și RNN, în continuare par să nu reușească să capteze nicio caracteristică, rămânând statice, totuși valoarea prognozei realizate de către ele este mai apropiată de datele reale decât cea realizată de VAR.

#### Limitări:

Cu toate că modelul LSTM a realizat previziuni foarte robuste, este incert cât de mult se poate baza cineva pe ele, dat fiind faptul că indicatorii macroeconomici depind în proporție foarte mare de factori politici sau sociali, ceea ce niciun algoritm matematic nu poate prezice.

#### Concluzii:

Rețele neuronale s-au dovedit a fi mai eficiente față de modelul VAR în realizarea prognozei unor indicatori economici. Modelul LSTM are un potențial foarte mare în realizarea prognozelor multivariate.